

我按 [final.pdf](#) 里的 Task 2 来筛：核心是 **LLM pretraining loss curve prediction across learning-rate schedules**，所以最相关的是学习率调度、Batch Size scaling、Adam/AdamW 动力学、动量/EMA、权重衰减、Muon 以及优化收敛视角。下面按相关性列出。

高度相关

Blog	大致内容	对大作业的启发
滑动平均视角下的权重衰减和学习率	把 AdamW/SGDM/RMSProp/Muon 等更新写成带 Weight Decay 的 EMA，讨论 LR schedule、WD schedule、Cosine、WSD 等动态情形。	非常贴近 Task 2，可把 loss curve 建模中的 schedule effect 理解为“历史梯度记忆权重”。 (spaces.ac.cn)
当Batch Size增大时，学习率该如何随之变化？	系统讨论 batch size 与学习率的 scaling law：平方根缩放、线性缩放、二阶损失近似、noise scale、数据效率。	对理解“LRS 为什么影响 loss dynamics”很有用，尤其是 η^* 、noise scale、训练步数/数据量关系。 (spaces.ac.cn)
Adam的epsilon如何影响学习率的Scaling Law?	分析 Adam 中 ϵ 对学习率 scaling law 的影响，把 Adam/SignSGD/SoftSignSGD 联系起来。	可用于解释 Adam 型优化器下，学习率并非简单乘性输入， ϵ 会改变有效步长。 (spaces.ac.cn)
重新思考学习率与Batch Size (一)：现状	回顾前两篇关于 Batch Size/LR 的工作，用二阶展开统一写成求最优学习率的问题。	适合作为理论背景页：为什么用 η 、梯度噪声、Hessian 近似解释 loss 下降。 (spaces.ac.cn)
重新思考学习率与Batch Size (二)：平均场	用平均场近似简化 SignSGD/SoftSignSGD 的学习率规律推导。	对你们做黑盒/半参数模型很有启发：可以把复杂优化器效应压缩成少数统计量。 (spaces.ac.cn)
重新思考学习率与Batch Size (三)：Muon	把前两篇方法推广到非 element-wise 的 Muon，讨论矩阵梯度、Hessian 线性算子、Batch Size scaling。	若 slides 里提优化器扩展，可以说明 Adam 以外的 schedule law 不一定同形。 (spaces.ac.cn)
重新思考学习率与Batch Size (四)：EMA	指出 Adam/Lion/Muon 中动量/EMA 是导致 Update RMS 差异的核心，而不只是 ϵ 。	对 loss curve 预测很关键：历史学习率不能只看当前 η_t ，还要看 EMA/momentum 状态。 (spaces.ac.cn)
为什么Adam的Update RMS是0.2?	用平均场近似解释 Adam 在 warmup 后 Update RMS 稳定在约 0.2-0.3 的现象。	可启发“有效更新幅度”特征：用 $\eta_t \ u_t\ _{\text{RMS}}$ 替代裸学习率。 (spaces.ac.cn)
AdamW的Weight RMS的渐近估计 (上)	从 AdamW 更新式推导 Weight RMS 与 η/λ 的渐近关系。	说明 LR 和 weight decay 共同决定权重尺度，不能只把 schedule 当作外部输入。 (spaces.ac.cn)
AdamW的Weight RMS的渐近估计 (下)	将上篇推广到动态学习率和动态 weight decay，明确提到 Cosine Decay、WSD。	与 Task 2 的 cosine-to-WSD 泛化最直接相关。 (spaces.ac.cn)

Blog	大致内容	对大作业的启发
让炼丹更科学 一些（一）： SGD的平均损失收敛	从 SGD 收敛理论出发，说明平均损失可由学习率策略控制。	可作为“loss curve 与 schedule 有理论关系”的基础材料，但假设较强。(spaces.ac.cn)
让炼丹更科学 一些（二）：将结论推广到无界域	放宽第一篇的有界域假设，把平均损失收敛结论推广到更一般设置。	对写“理论启发但不能直接解释 LLM 非凸训练”很适合。(kexue.fm)
让炼丹更科学 一些（三）： SGD的终点损失收敛	从平均损失转到终点损失，讨论训练结束时 θ_T 的 loss 收敛。	贴合 loss curve prediction 里的“最终/未来 loss 外推”。(kexue.fm)
让炼丹更科学 一些（四）：新恒等式，新学习率	讨论线性衰减学习率为何能改善终点收敛，并提到与 Scaling Law 实践的联系。	可作为对 cosine/WSD/linear decay 差异的理论背景。(kexue.fm)

相关但偏拓展

Blog	大致内容	用法
从Hessian近似看自适应学习率优化器	把 Adam/RMSProp 看成近似二阶 Newton 法。	可解释为什么自适应优化器的有效 learning rate 与曲率相关。(spaces.ac.cn)
为什么梯度裁剪的默认模长是1？	讨论 global grad norm clipping 的尺度问题。	若 loss 曲线中有异常尖峰，可作为稳定性解释。(spaces.ac.cn)
基于Amos优化器思想推导出来的一些“炼丹策略”	讨论学习率如何适应初始化/参数化、权重衰减率、学习率策略、优化器显存。	可用于调参经验综述，不宜作为核心实验依据。(spaces.ac.cn)
隐藏在动量中的梯度累积：少更新几步，效果反而更好？	说明动量优化器中可以内置梯度累积，少更新可能更稳。	对“历史信息/有效步数”建模有启发。(spaces.ac.cn)
从动力学角度看优化算法（一）：从SGD到动量加速	用 ODE/动力学视角解释 SGD、Momentum、Nesterov。	适合讲 problem introduction。(spaces.ac.cn)
从动力学角度看优化算法（二）：自适应学习率算法	从 RMSProp 到 Adam 的自适应学习率机制。	可作为 Adam 背景。(spaces.ac.cn)
从动力学角度看优化算法（五）：为什么	有限学习率可能带来隐式梯度正则，过小不一定更好。	可解释“最佳 schedule 不是单调趋零越快越好”。(spaces.ac.cn)

Blog	大致内容	用法
么学习率不宜过小?		
初探MuP：超参数的跨模型尺度迁移规律	介绍 MuP 与小模型到大模型的超参数迁移。	若讨论 scaling law，可作为模型尺度迁移背景。 (spaces.ac.cn)
MuP之上：1. 好模型三个特征	讨论 Muon 与 MuP 的联系、模型优化中的尺度与更新原则。	适合拓展“为什么 schedule/optimizer/parameterization 不能分开看”。(spaces.ac.cn)
Muon优化器指南：快速上手与关键细节	介绍 Muon 的背景、实现与从 Adam 迁移的关键细节。	如果 slides 提到 Adam/Muon，可作为实践参考。(spaces.ac.cn)
QK-Clip：让Muon在Scaleup之路上更进一步	讨论 Muon scale-up 中 MaxLogit 爆炸和 QK-Clip。	与 loss curve 预测间接相关，主要是稳定性案例。(spaces.ac.cn)
流形上的最速下降：1-5	从约束/流形/谱范数角度解释 SGD、Muon、正交约束、Stiefel、谱球面、对偶梯度下降。	数学味很重，可作为 Muon 原理背景，不建议放入主线太多。(spaces.ac.cn)
msign算子的Newton-Schulz迭代（下）	讨论 Muon 中 matrix sign / Newton-Schulz 近似。	偏实现和数值近似，对当前任务是低优先级。 (spaces.ac.cn)
AdaFactor优化器浅析 / AdaX优化器浅析	介绍省显存或长记忆自适应优化器。	与 LLM 预训练优化器背景相关，但不直接服务 cosine/WSD loss prediction。(spaces.ac.cn)

我的建议：真正值得放进你们大作业“方法启发”的，是前 14 篇；后面这些可作为 backup 或答辩时补充，不要把主线扩散成“优化器综述”。